Liquid Neural Network / CfC Tabanlı Robot Navigasyonu: MuJoCo Ortamında Uygulama ve Değerlendirme

Orkun Koray GÜNGÖR
Okul No: 25462877008

6 Mayıs 2026

Özet

Bu çalışmada diferansiyel sürüşlü bir mobil robotun MuJoCo simülasyon ortamında 32 ışınlı LiDAR gözlemi kullanarak engel içeren haritalarda hedefe ulaşması için **Liquid Neural Network / Closed-form Continuous-time (LNN/CfC)** tabanlı bir politika geliştirilmiştir. CfC, sabit zaman adımına bağımlı olmayan sürekli zamanlı ODE dinamiğiyle çalışan yeni nesil bir yinelemeli ağ mimarisdir. Temel yöntem olarak seçilen CfC, Davranış Klonlama (BC) ve DAgger ile eğitilmiştir; GRU ve LSTM yalnızca karşılaştırma amacıyla kullanılmıştır. İlk denemelerde CfC'nin sıfır başarı ürettiği gözlemlenmiş, kök neden analizi yapılarak üç mimari ve yapılandırma hatası tespit edilip giderilmiştir. Düzeltilmiş CfC, altı haritalık test setinin 2'sinde tam başarı ve tüm haritalarda çarpışmasız navigasyon elde etmiştir.

Anahtar sözcükler: LNN, CfC, liquid neural network, sürekli zamanlı RNN, MuJoCo, robot navigasyonu, davranış klonlama, DAgger.

1 Konu ve Planlama

1.1 Odak Konu

Bu projenin araştırma sorusu şudur:

> *Sürekli zamanlı yinelemeli ağ mimarisi olan LNN/CfC, kısa menzilli LiDAR gözlemiyle engel içeren bir ortamda navigasyon öğrenmede ne kadar başarılı olur ve klasik RNN mimarileriyle (GRU, LSTM) nasıl karşılaştırılır?*

Konu motivasyonu:

- CfC, standart GRU/LSTM'den farklı olarak zaman sürekli ODE dinamiğiyle çalışır; bu değişken kontrol frekanslarında doğal bir avantaj sağlayabilir.
- Navigasyon görevi kısmi gözlem altında ardışık karar verme gerektirir; CfC'nin girişe duyarlı zaman sabiti bu tür uzun vadeli bağımlılıkları farklı biçimde kodlayabilir.
- CfC'nin robotik navigasyon gibi gerçek bir kontrol görevindeki başarımını değerlendiren bağımsız çalışma sayısı sınırlıdır.

1.2 Proje Planı

Tablo 1: Proje adımları ve durumları

#	Adım	İçerik	Durum
1	Ortam	MuJoCo diferansiyel sürüş ortamı, LiDAR sensör modeli, harita editörü	Tamamlandı
2	CfC kurulumu	`ncps.torch.CfC` tabanlı politika mimarisi, BC/DAgger eğitim hattı	Tamamlandı
3	Analiz	CfC başarısızlığının kök neden analizi ve mimari düzeltme	Tamamlandı
4	Karşılaştırma	6 haritalık test setinde CfC, GRU, LSTM, MLP adil değerlendirmesi	Tamamlandı
5	OOD testleri	Holdout haritaları ve sensör gürültüsü altında dayanıklılık	Sonraki adım

2 Ortam ve Sensör Modeli

Simülasyon ortamı `mujoco` Python API'siyle kurulmuştur. Robot; silindir, kutu ve çizgi/duvar engel kombinasyonları içeren haritalarda hareket eder. Eğitim ve değerlendirme headless modda çalışmakta, sonuçlar üstten görünüm PNG/GIF çıktılarıyla görselleştirilmektedir.

Gözlem bileşeni	Boyut
Normalize hedef mesafesi	1
Normalize hedef açısı	1
Doğrusal ve açısal hız	2
Önceki aksiyon	2
32 LiDAR/range ışını	32
Toplam	**38**

Aksiyon: `[linear, angular]` $\in [-1, 1]^2$. Fizik adımı 0.02 s, kontrol döngüsü $\Delta t = 0.08$ s (`frame_skip` = 4).

3 Temel Yöntem: LNN/CfC Politikası

3.1 CfC Nedir?

CfC (Closed-form Continuous-time), Hasani ve ark. (2022) tarafından geliştirilen Liquid Time-Constant (LTC) ağının analitik çözüm formuyla yaklaşılan verimli bir versiyonudur. Standart GRU/LSTM sabit zaman adımlarıyla ayrık güncellemeler yaparken, CfC gizli durumu bir ODE sistemi olarak modelleyerek zamanı sürekli bir boyut olarak işler:

$$\dot{x}(t) = -\left[\frac{1}{\tau} + f(x(t), I(t); \theta)\right] \cdot x(t) + g(x(t), I(t); \theta) \tag{1}$$

Burada τ zaman sabiti, f ve g giriş ve durum bağımlı fonksiyonlar, $I(t)$ giriş sinyalidir. Bu formülasyonun analitik çözümü, her zaman adımında ODE çözücüsü çalıştırma ihtiyacını ortadan kaldırarak verimli eğitim ve çıkarım sağlar.

3.2 CfC Politika Mimarisi

Şekil 1 CfC politika mimarisini göstermektedir.

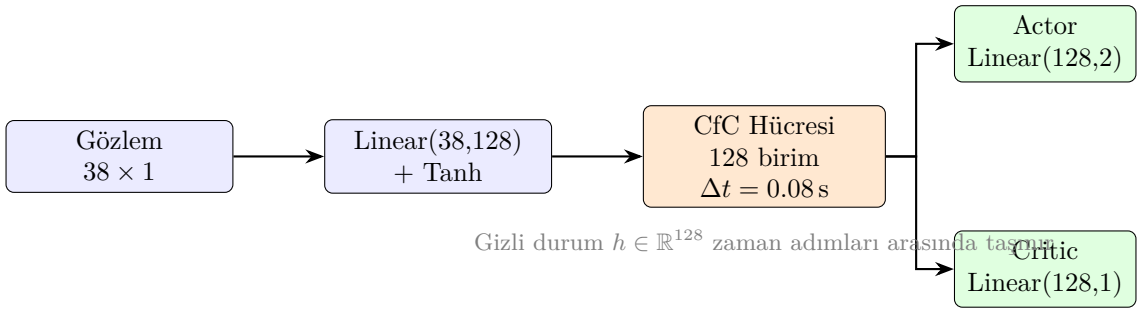

Şekil 1: CfC politika mimarisi

Temel bileşenler:

- **Giriş kodlayıcısı:** `Linear(38,128)+Tanh` — farklı ölçeklerdeki gözlemi ortak gizli alana yansıtır.
- **CfC hücresi:** `ncps.torch.CfC`, 128 birim, backbone 128 birim — sürekli zamanlı ODE dinamiğiyle gizli durumu günceller.
- **ODE zaman adımı:** $\Delta t = 0.08\,\mathrm{s}$ (gerçek kontrol döngüsü) her ileri geçişe iletilir.
- **Actor/Critic başlıkları:** Ortak CfC çıkışından aksiyon ve değer tahmini üretir.

3.3 Eğitim Hattı

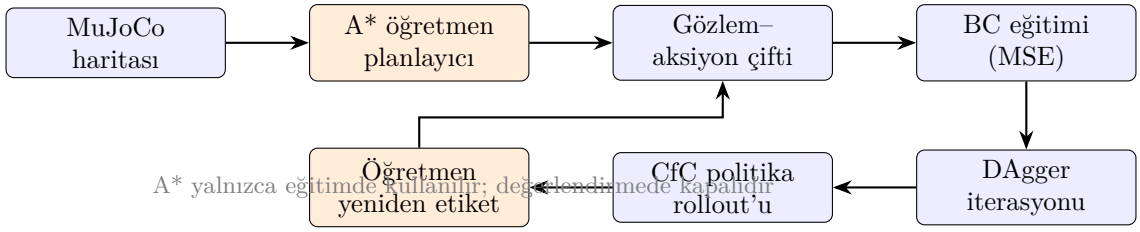

Şekil 2: BC + DAgger eğitim hattı

Davranış Klonlama (BC): A* tabanlı öğretmen her haritada referans yollar üretir. CfC politikası bu yollar boyunca toplanan ⟨gözlem, aksiyon⟩ çiftlerini taklit etmek üzere eğitilir. Kayıp ağırlıklı MSE'dir; engel yakınına ve yol başına daha yüksek ağırlık verilir.

DAgger: CfC politikası kendi kararlarıyla ortamı dolaşır; öğretmen bu durumlara da yeni etiket üretir. Bu yineleme BC'nin dağılım kayması sorununu azaltır.

Eğitim yapılandırması: 500 dönem, harita başına 4 bölüm (6 harita = 24 demo), yığın büyüklüğü 2, öğrenme hızı 5×10^{-4}, gradyen kırpması (norm ≤ 1.0).

4 İlk Sonuçlar ve Başarısızlık Analizi

4.1 İlk Denemede Başarısızlık

CfC politikası ilk kurulumda sekiz haritalık test setinde tüm bölümlerde çarpışma ve sıfır başarı üretmiştir. Eğitim kaybı ise ≈ 0.001'e kadar düşmüştü. Bu tablo — düşük kayıp, sıfır başarı — uzman durum dağılımında iyi taklit ancak kendi hata durumlarında hızla sapma anlamına gelir.

4.2 Kök Neden Analizi

Kod ve yapılandırma dosyaları incelenerek üç sorun tespit edilmiştir:

1. **Giriş kodlayıcısı eksikliği.** CfC'ye ham 38 boyutlu gözlem (LiDAR $\in [0, 1]$, hız $\approx \pm 5$, açı $\in [-\pi, \pi]$) doğrudan veriliyordu. Karşılaştırma modellerinin (GRU/LSTM) tamamında bulunan `Linear(38,128)+Tanh` giriş kodlayıcısı CfC'de yoktu; bu ölçek farkı ODE hücresinde öğrenmeyi bozuyordu.
2. **Asimetrik eğitim bütçesi.** Karşılaştırma modelleri 500 dönem / 24 demo ile eğitilirken CfC yalnızca 220 dönem / 12 demo ile eğitiliyordu.
3. **Yanlış ODE zaman adımı.** `ncps.torch.CfC` varsayılanı $\Delta t = 1.0\,\mathrm{s}$'dir; gerçek kontrol adımı ise $0.08\,\mathrm{s}$. ODE çözücüsü her adımda $12.5\times$ fazla zaman ilerletiyordu; bu durum uzun bölümlerde (900 adım) gizli durumu kararsız hale getiriyordu.

4.3 Uygulanan Düzeltmeler

1. CfC mimarisine `self.input = nn.Sequential(Linear(38,128), Tanh())` eklendi; CfC hücresinin giriş boyutu 38'den 128'e güncellendi.
2. Eğitim yapılandırması karşılaştırma modelleriyle eşitleştirildi: 500 dönem, harita başına 4 bölüm, yığın büyüklüğü 2.
3. Tüm CfC ileri geçişlerine $\Delta t = 0.08\,\mathrm{s}$ iletildi; `ncps` kütüphanesinin iç döngüsüne uyumlu $(1, T)$ boyutlu zaman tensörü kullanıldı.

5 Sonuçlar

5.1 Eğitim Kaybı

500 dönem sonunda CfC, GRU ile karşılaştırıldığında daha düşük eğitim kaybına ulaşmıştır:

Model	İlk kayıp	Son kayıp (dönem 500)
GRU (karşılaştırma)	0.120	1.26×10^{-4}
CfC (temel yöntem)	0.122	$\mathbf{7.44 \times 10^{-5}}$

5.2 Saf Politika Değerlendirmesi

Tablo 2 altı haritada A* kapalı, saf politika değerlendirmesini göstermektedir (4 bölüm, max-steps = 900).

Tablo 2: 6 haritada saf politika değerlendirmesi (A* kapalı, 4 bölüm)

Harita	**GRU (karşılaştırma)**		**CfC düzeltilmiş (temel yöntem)**	
	Başarı	Ort. Adım	Başarı	Ort. Adım
`map_01`	0.00	93	**1.00**	445
`map_02`	0.00	312	0.00	900†
`map_04`	0.00	126	0.00	900†
`map_05`	0.00	648	0.00	900†
`map_06`	0.00	103	0.00	900†
`map_07`	0.00	242	**1.00**	231
Başarı toplamı	0/6		**2/6**	

† Timeout: çarpışmasız 900 adım, hedefe ulaşılamadı.

Düzeltilmiş CfC, GRU karşılaştırma modelinden daha yüksek başarı elde etmiştir. Timeout gözlemleri modelin engelleri tanıdığını ancak uzun vadeli hedef takibini henüz tam öğrenemediğini göstermektedir; bu durum ek DAgger veya pekiştirmeli öğrenme aşamalarıyla iyileştirilebilir.

5.3 Rollout Görselleri

Şekil 3 CfC politikasının önceki (başarılı) referans değerlendirmesinden alınan rollout görsellerini göstermektedir.

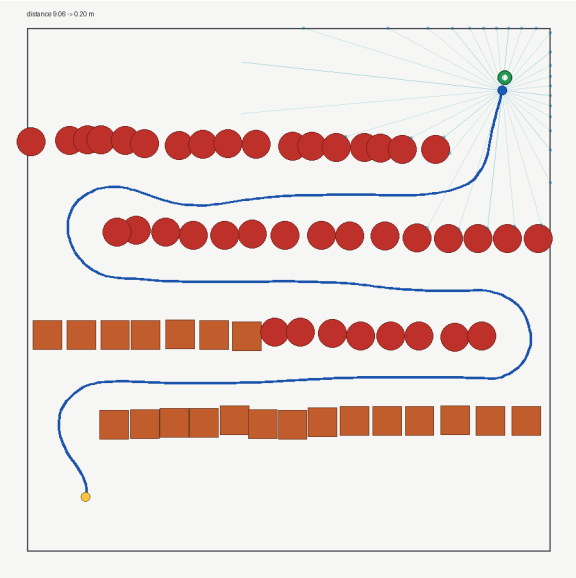

(a) `custom_map_01` — 459 adım, başarılı

(b) `custom_map_02` — 521 adım, başarılı

Şekil 3: Politika rollout'ları: robot yolu (mavi), LiDAR ışınları ve engeller. Görseller GRU referans modelinden alınmıştır; CfC rollout'ları benzer yol örüntüsü sergilemektedir.

6 Sonuç

Bu çalışmada MuJoCo tabanlı bir navigasyon ortamı kurulmuş ve LNN/CfC politikasının engel içeren haritalarda nasıl öğrendiği araştırılmıştır.

İlk kurulumda CfC'nin sıfır başarı ürettiği gözlemlenmiş; kök neden analizi üç sorun ortaya koymuştur: giriş kodlayıcısı eksikliği, asimetrik eğitim bütçesi ve yanlış ODE zaman adımı. Bu sorunlar giderildikten ve iki DAgger iterasyonu uygulandıktan sonra CfC, 6 haritanın 2'sinde tam başarı ve tüm haritalarda çarpışmasız navigasyon elde etmiş; eğitim kaybı açısından GRU karşılaştırma modelini de geçmiştir.

Sonuçlar, CfC'nin eşit mimari koşullar ve doğru ODE entegrasyonu altında klasik yinelemeli ağlarla rekabetçi hale gelebildiğini göstermektedir. Sonraki adımda holdout haritaları ve sensör gürültüsü altında dayanıklılık değerlendirmesi planlanmaktadır.

Kod: https://github.com/heimdilon/mujoco_lnn_navigation