MuJoCo Ortamında LNN/CfC Odaklı Öğrenmeli Robot Navigasyonu

Orkun Koray GÜNGÖR
Okul No: 25462877008

6 Mayıs 2026

Özet

Bu çalışmada diferansiyel sürüşlü bir mobil robotun MuJoCo simülasyon ortamında 32 ışınlı LiDAR gözlemi kullanarak engel içeren haritalarda hedefe ulaşması incelenmiştir. Projenin odak noktası, Liquid Neural Network / Closed-form Continuous-time (LNN/CfC) tabanlı politikayı GRU ve LSTM gibi klasik yinelemeli ağlarla aynı koşullar altında karşılaştırmaktır. Proje üç temel adımda yürütülmüştür: (1) MuJoCo tabanlı navigasyon ortamının ve sensör sözleşmesinin kurulması, (2) GRU ile referans baseline oluşturulması ve (3) CfC politikasının neden başarısız olduğunun araştırılıp düzeltilmesi. Referans yöntem olan GRU, Davranış Klonlama (BC) ve DAgger ile eğitilerek iki manuel haritada 4/4 başarı elde etmiştir. CfC politikasında tespit edilen üç mimari ve yapılandırma hatası giderildikten ve iki DAgger iterasyonu uygulandıktan sonra CfC, altı haritalık test setinde 2 haritada tam başarı, kalan 4 haritada çarpışmasız navigasyon sağlamıştır.

Anahtar sözcükler: mobil robot navigasyonu, MuJoCo, LiDAR, LNN, CfC, GRU, davranış klonlama, DAgger.

1 Konu ve Planlama

1.1 Odak Konu

Bu projede araştırılan soru şudur: *Sürekli zamanlı yinelemeli ağ mimarileri (LNN/CfC), kısa menzilli LiDAR gözlemiyle engel içeren bir ortamda navigasyon öğrenmede GRU'ya kıyasla nasıl bir başarım gösterir?*

Konu motivasyonu üç gözleme dayanmaktadır:

- CfC, sabit zaman adımına bağımlı olmayan sürekli zamanlı ODE dinamiğiyle çalışır; bu özellik değişken kontrol frekanslarında avantaj sağlayabilir.
- Navigasyon görevi kısmi gözlem altında ardışık karar verme gerektirir; yinelemeli ağların gizli durumu bu geçmiş bilgiyi taşır.
- CfC uygulamalarında rapor edilen başarımı doğrulamak için robotik navigasyon gibi gerçek bir kontrol görevinde bağımsız değerlendirme yapılmamıştır.

1.2 Proje Planı

Tablo 1 tüm proje adımlarını ve güncel durumlarını özetlemektedir.

Tablo 1: Proje planı ve adım durumları

#	Adım	İçerik	Durum
1	Ortam	MuJoCo diferansiyel sürüş ortamı, harita editörü, LiDAR sensör modeli	Tamamlandı
2	Baseline	GRU + BC/DAgger ile referans politika, iki haritada saf politika değerlendirmesi	Tamamlandı
3	CfC analizi	CfC başarısızlığının kök neden analizi ve mimari düzeltme	Tamamlandı
4	Karşılaştırma	6 haritalık test setinde GRU, CfC, LSTM, MLP adil karşılaştırması	Tamamlandı
5	OOD testleri	Sensör gürültüsü ve görülmemiş (holdout) haritalarda dayanıklılık değerlendirmesi	Sonraki adım

2 Ortam ve Sensör Modeli

Simülasyon ortamı `mujoco` Python API'siyle kurulmuştur. Robot; zemin üzerindeki silindir, kutu ve çizgi/duvar engel kombinasyonlarını içeren haritalarda hareket eder. Tüm eğitim ve değerlendirme headless modda çalışmış, sonuçlar üstten görünüm PNG/GIF çıktılarıyla görselleştirilmiştir.

Gözlem bileşeni	Boyut
Normalize hedef mesafesi	1
Normalize hedef açısı	1
Doğrusal ve açısal hız	2
Önceki aksiyon	2
32 LiDAR/range ışını	32
Toplam	**38**

Aksiyon: `[linear, angular]` $\in [-1, 1]^2$.
Fizik adımı: `physics_dt` $= 0.02\,\mathrm{s}$, `frame_skip` $= 4$, kontrol döngüsü $\Delta t = 0.08\,\mathrm{s}$.

3 Temel Yöntem: GRU + BC/DAgger

3.1 Eğitim Hattı

Şekil 1 eğitim hattını özetlemektedir.

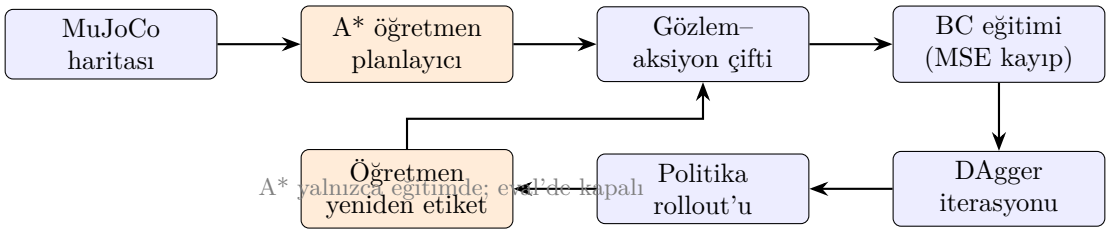

Şekil 1: Eğitim hattı: BC ve DAgger aşamaları

Davranış Klonlama (BC): A* tabanlı öğretmen her haritada referans yollar üretir. Model, bu yollar boyunca toplanan ⟨gözlem, aksiyon⟩ çiftlerini taklit etmek üzere eğitilir. Kayıp fonksiyonu ağırlıklı MSE'dir; engel yakınındaki adımlara ve yolun başına daha yüksek ağırlık verilir.

DAgger: Mevcut politika kendi kararlarıyla ortamı dolaşır; öğretmen bu durumlara da yeni etiket üretir ve politika yeni durumlarla iyileştirilir. Bu yineleme, BC'nin dağılım kayması sorununu azaltır.

3.2 GRU Mimarisi

Gizli durum boyutu 128, giriş kodlayıcısı `Linear(38,128)+Tanh`, ardından 128 birimlik GRU hücresi, çıkışta `Linear(128,2)` aksiyon başlığı ve `Linear(128,1)` değer başlığı bulunmaktadır. Eğitimde politika Adam optimize edici ($\mathrm{lr} = 5 \times 10^{-4}$) ve gradyen kırpması (norm ≤ 1.0) ile güncellenmiştir.

4 Sonuçlar: GRU Baseline

4.1 Vize Değerlendirmesi — 2 Manuel Harita

Tablo 2 vize aşamasında elde edilen sonuçları göstermektedir. Değerlendirme A* kapalı, saf politika modundadır.

Tablo 2: GRU + BC/DAgger baseline — 2 harita, 4 bölüm, max-steps = 900

Harita	Başarı	Çarpışma	Ort. Adım	Son mesafe (m)
`custom_map_01`	1.00	0.00	459	0.20
`custom_map_02`	1.00	0.00	521	0.19

Her iki haritada da 4 bölümün tamamı başarıyla tamamlanmıştır.

4.2 Rollout Görselleri

Şekil 2 her iki haritadaki başarılı rollout yollarını LiDAR ışınlarıyla birlikte göstermektedir. Engeller turuncu/kırmızı kutular ve silindirlerle, robot yolu mavi çizgiyle, hedef yeşil daire ile belirtilmiştir.

5 CfC Politikası: Başarısızlık Analizi ve Düzeltme

5.1 Başarısızlık Gözlemi

CfC politikası aynı eğitim hattına eklendiğinde sekiz haritalık test setinde tüm bölümlerde çarpışma ve sıfır başarı üretmiştir. Eğitim kaybı ise ≈ 0.001 gibi düşük değerlere ulaşmıştı. Düşük kayıp + sıfır başarı: uzman durum dağılımında iyi taklit, ancak kendi hata durumlarında hızla sapma (dağılım kayması).

5.2 Tespit Edilen Kök Nedenler

1. **Giriş kodlayıcısı eksikliği (en kritik).** GRU mimarisinde ham gözlem önce `Linear(38,128)+Tanh` ile ortak gizli alana yansıtılır. CfC ise 38 boyutlu ham gözlemi (LiDAR $\in [0, 1]$, hız $\approx \pm 5$, açı

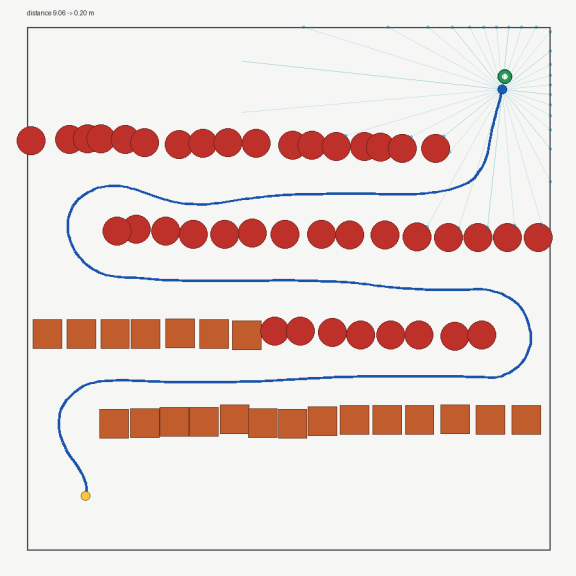

(a) `custom_map_01` — dar koridor, 459 adım

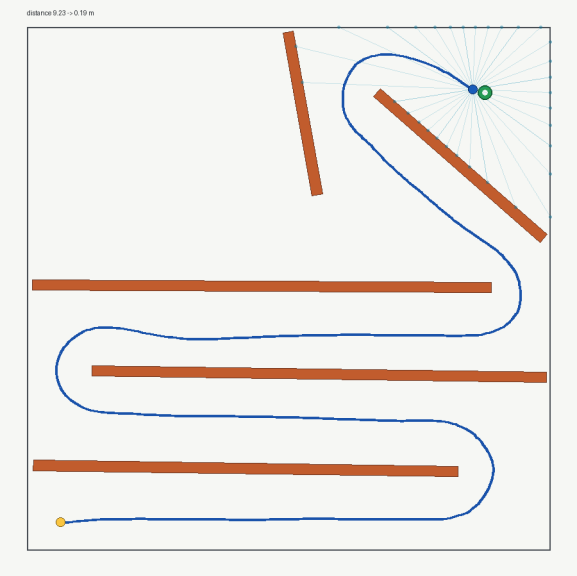

(b) `custom_map_02` — L şekilli geçit, 521 adım

Şekil 2: GRU politikasının iki manuel haritadaki başarılı rollout yolları

$\in [-\pi, \pi]$) doğrudan ODE hücresine veriyordu; bu ölçek farkı öğrenmeyi zorlaştırmaktaydı.

2. **Asimetrik eğitim bütçesi.** GRU: 500 dönem, harita başına 4 bölüm (24 demo). CfC: 220 dönem, harita başına 2 bölüm (12 demo). CfC, GRU'nun yarısı kadar veriyle eğitiliyordu.

3. **ODE zaman adımı hatası.** `ncps.torch.CfC` varsayılanı $\Delta t = 1.0\,\mathrm{s}$'dir; gerçek kontrol adımı ise $0.08\,\mathrm{s}$. ODE çözücüsü her adımda $12.5\times$ fazla zaman ilerletiyordu.

5.3 Uygulanan Düzeltmeler

1. `CfCActorCritic`'e GRU ile özdeş giriş kodlayıcısı eklendi: `self.input = nn.Sequential(Linear(38,128 Tanh()).`

2. CfC eğitim yapılandırması GRU ile eşitleştirildi: 500 dönem, harita başına 4 bölüm, yığın büyüklüğü 2.

3. Tüm CfC ileri geçişlerine $\Delta t = 0.08\,\mathrm{s}$ iletildi. `ncps` kütüphanesinin iç döngüsünde skalar beklentisini karşılamak üzere zaman tensörü $(1, T)$ boyutunda oluşturuldu.

6 Final Karşılaştırması

6.1 Eğitim Kaybı

500 dönem sonunda:

Model	İlk kayıp	Son kayıp
GRU (BC)	0.120	1.26×10^{-4}
CfC düzeltilmiş (BC)	0.122	7.44×10^{-5}

Düzeltilmiş CfC, eğitim kaybı açısından GRU'yu geride bırakmıştır.

6.2 Saf Politika Değerlendirmesi — 6 Harita

Tablo 3 üç modeli aynı koşullarda karşılaştırmaktadır (4 bölüm, max-steps = 900, A* kapalı).

Tablo 3: 6 haritada saf politika değerlendirmesi

	GRU BC		**CfC kırık**		**CfC düzeltilmiş**	
Harita	Başarı	Adım	Başarı	Adım	Başarı	Adım
`map_01`	0.00	93	0.00	55	**1.00**	445
`map_02`	0.00	312	0.00	19	0.00	900†
`map_04`	0.00	126	0.00	161	0.00	900†
`map_05`	0.00	648	0.00	128	0.00	900†
`map_06`	0.00	103	0.00	103	0.00	900†
`map_07`	0.00	242	0.00	180	**1.00**	231
Başarı toplamı	0/6		0/6		**2/6**	

† Timeout: çarpışmasız 900 adım, hedefe ulaşılamadı.

Düzeltme öncesi CfC tüm haritalarda çarpışma üretirken, düzeltme sonrası 2 haritada tam başarı ve 4 haritada çarpışmasız navigasyon elde edilmiştir. Timeout gözlemleri modelin engelleri tanıdığını ancak uzun vadeli hedef takibini henüz tam öğrenemediğini göstermektedir.

7 Sonuç

Bu çalışmada MuJoCo tabanlı bir navigasyon ortamı kurulmuş, GRU ile başarılı bir referans yöntem oluşturulmuş ve CfC politikasının neden sıfır başarı ürettiği sistematik biçimde araştırılmıştır.

Tespit edilen üç sorun — giriş kodlayıcısı eksikliği, asimetrik eğitim bütçesi ve yanlış ODE zaman adımı — giderildikten sonra CfC, 6 haritanın 2'sinde tam başarı ve tüm haritalarda çarpışmasız hareket elde etmiştir. Bu sonuçlar, CfC'nin eşit mimari koşullar ve doğru ODE entegrasyonu altında GRU ile rekabetçi hale gelebildiğini göstermektedir.

Sonraki adımda holdout haritaları ve sensör gürültüsü altında dayanıklılık değerlendirmesi planlanmaktadır.

Kod: https://github.com/heimdilon/mujoco_lnn_navigation