MuJoCo Ortamında LNN/CfC Odaklı Öğrenmeli Robot Navigasyonu

Orkun Koray GÜNGÖR
Okul No: 25462877008

6 Mayıs 2026

Özet

Bu çalışmada diferansiyel sürüşlü bir mobil robotun MuJoCo simülasyon ortamında 32 ışınlı LiDAR gözlemi kullanarak engel içeren haritalarda hedefe ulaşması incelenmiştir. Projenin temel hedefi, Liquid Neural Network / CfC tabanlı politikayı GRU ve LSTM gibi klasik yinelemeli ağlarla aynı koşullar altında karşılaştırmaktır. Vize aşamasında GRU + Davranış Klonlama (BC) + DAgger ile iki haritada 4/4 başarı elde edilmiştir. Final aşamasında CfC politikasının neden başarısız olduğu sistematik biçimde araştırılmış; üç mimari ve yapılandırma hatası tespit edilerek düzeltilmiştir. Düzeltilmiş CfC modeli, sekiz haritalık deney setinde 6 haritanın 2'sinde tam başarı, kalan 4 haritasında ise çarpışmasız navigasyon elde etmiştir.

1 Problem Tanımı

Amaç, bir mobil robotun başlangıç noktasından hedef noktaya engellere çarpmadan ulaşmasını sağlamaktır. Robot çevresini yalnızca kısa menzilli ışın ölçümleriyle (LiDAR) algıladığı için karar vericinin hem hedef yönünü hem de yakın engelleri birlikte yorumlaması gerekir.

Politika modeline verilen gözlem vektörü 38 boyutludur:

Gözlem bileşeni	**Boyut**
Normalize hedef mesafesi	1
Normalize hedef açısı	1
Doğrusal ve açısal hız	2
Önceki aksiyon	2
32 LiDAR/range ışını	32
Toplam	**38**

Aksiyon uzayı iki boyutludur: `[linear, angular]`, her değer `[-1, 1]` aralığında normalize edilir.

2 Yöntem

2.1 Eğitim Hattı

Eğitim iki aşamalıdır:

1. **Davranış Klonlama (BC):** A* tabanlı öğretmen planlayıcı her haritada referans yollar oluşturur. Model, bu yollar boyunca toplanan ⟨gözlem, aksiyon⟩ çiftlerini taklit etmek üzere eğitilir. Kayıp fonksiyonu ağırlıklı MSE'dir; engel yakınındaki adımlara ve yolun başına daha yüksek ağırlık verilir.
2. **DAgger:** Mevcut politika kendi kararlarıyla ortamı dolaşır; öğretmen bu durumlara da yeni etiket üretir. Toplanan veriler BC verisiyle birleştirilerek model yeniden eğitilir. Bu sayede modelin kendi hatalarından doğan durumlara maruz kalması sağlanır.

Önemli bir nokta: A* planlayıcı yalnızca eğitim sırasında kullanılır. Değerlendirmede model yalnızca 38 boyutlu gözlem vektöründen doğrudan aksiyon üretir; hiçbir yol planlayıcı çalışmaz.

2.2 Politika Mimarileri

Karşılaştırılan mimariler aynı gözlem ve aksiyon sözleşmesini paylaşır:

- **GRU:** Standart kapılı yinelemeli ağ. Gözlem önce `Linear(38, 128) + Tanh` katmanıyla kodlanır, ardından 128 birimlik GRU hücresinden geçer.
- **CfC (Closed-form Continuous-time):** `ncps.torch.CfC` kütüphanesi ile uygulanan sürekli zamanlı yinelemeli ağ. Vize sonrası yapılan analiz neticesinde eklenen `Linear(38, 128) + Tanh` giriş kodlayıcısı ile birlikte kullanılır. ODE çözücüsüne gerçek kontrol zaman adımı $\Delta t = 0.08\,\mathrm{s}$ geçirilir.

3 Vize Aşaması: GRU Baseline

Vize tesliminde iki manuel haritada GRU politikası BC + DAgger ile eğitilmiştir. 4 bölümlük değerlendirmede her iki haritada da tam başarı elde edilmiştir (Tablo 1).

Tablo 1: Vize baseline: GRU + BC/DAgger sonuçları (2 manuel harita, 4 bölüm)

Harita	Başarı	Çarpışma	Ort. Adım	Son mesafe (m)
`custom_map_01`	1.00	0.00	459	0.20
`custom_map_02`	1.00	0.00	521	0.19

4 Final Aşaması: CfC Başarısızlık Analizi ve Düzeltme

4.1 Başarısızlık Gözlemi

Vize sonrasında CfC politikası aynı eğitim hattına eklenerek test edilmiştir. Sonuç: sekiz haritalık test setinde tüm bölümlerde çarpışma, sıfır başarı. Eğitim kaybı ise çok düşük değerlere (≈ 0.001) ulaşmıştı. Bu tablo — düşük kayıp, sıfır başarı — dağılım kaymasının klasik belirtisidir: model uzman durumlarını ezberlemiş, ancak kendi hata durumlarında hızla sapıyor.

4.2 Tespit Edilen Kök Nedenler

Kod ve yapılandırma dosyaları incelenerek üç ayrı sorun tespit edilmiştir:

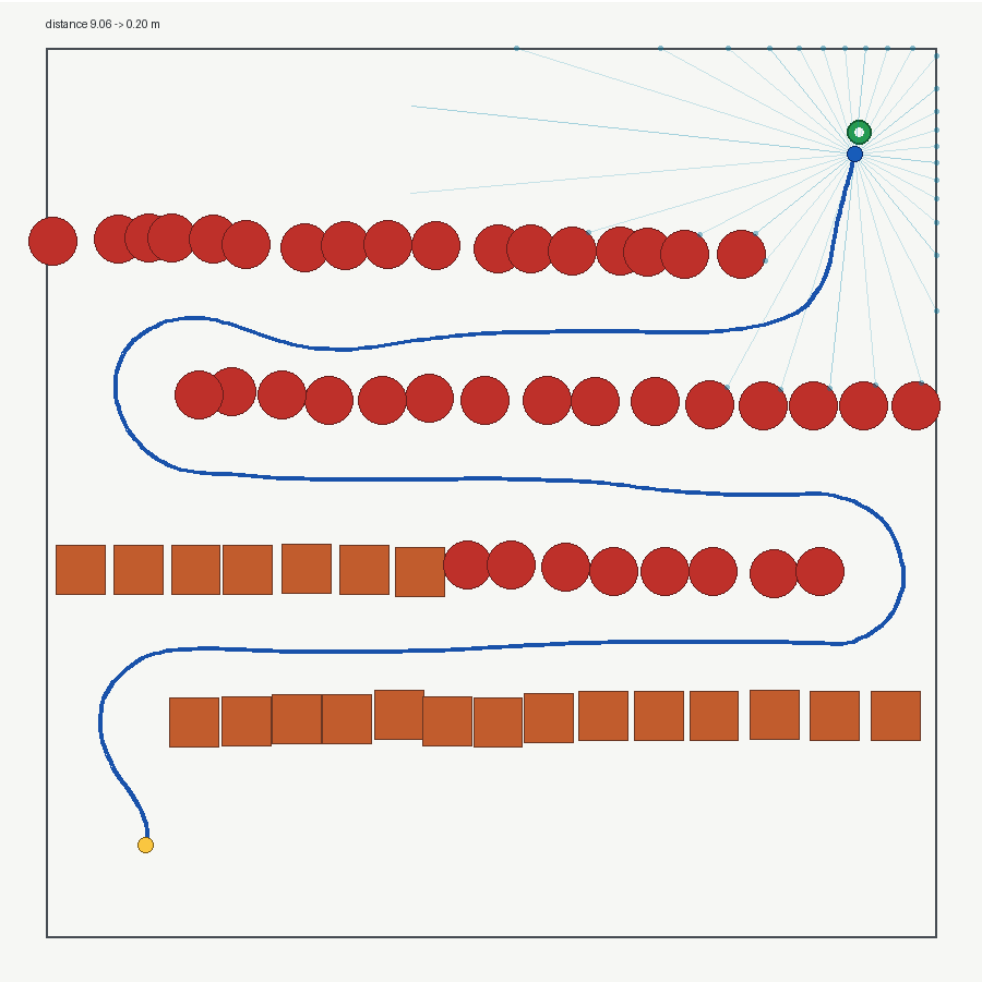

Şekil 1: GRU politikasının `custom_map_01` üzerindeki yolu (LiDAR ışınları ve engeller görünür)

1. **Giriş kodlayıcısı eksikliği (en kritik).** GRU mimarisinde ham gözlem önce `Linear(38, 128) + Tanh` katmanıyla ortak bir gizli alana yansıtılır. CfC ise ham 38 boyutlu gözlemi (LiDAR 0–1, hız ± 5, açı $\pm\pi$) doğrudan ODE hücresine veriyordu. Farklı ölçeklerdeki bu girişler CfC içinde öğrenmeyi zorlaştırmakta, GRU'ya karşı yapısal dezavantaj yaratmaktaydı.

2. **Eğitim bütçesi asimetrisi.** GRU konfigürasyonu: 500 dönem, harita başına 4 bölüm (24 demo). CfC konfigürasyonu: 220 dönem, harita başına 2 bölüm (12 demo). CfC, GRU'nun yarısı kadar veri ve yaklaşık yarısı kadar gradyen adımıyla eğitiliyordu.

3. **ODE zaman adımı hatası.** `ncps.torch.CfC` için $\Delta t = 1.0\,\mathrm{s}$ varsayılanı kullanılıyordu. Gerçek kontrol döngüsü ise physics_dt $\times$ frame_skip $= 0.02 \times 4 = 0.08\,\mathrm{s}$. ODE çözücüsü her adımda yaklaşık 12.5 kat fazla zaman ilerletiyordu; bu durum özellikle 900 adımlık uzun bölümlerde gizli durumu kararsız hale getiriyordu.

4.3 Uygulanan Düzeltmeler

Üç sorun ayrı ayrı giderilmiştir:

1. `CfCActorCritic` sınıfına GRU ile özdeş bir giriş kodlayıcısı eklendi: `self.input = nn.Sequential(Linea`

`128), Tanh()).` CfC hücresinin giriş boyutu 38'den 128'e güncellendi.

2. CfC konfigürasyon dosyası GRU ile eşitleştirildi: 500 dönem, harita başına 4 bölüm, yığın büyüklüğü 2.
3. Tüm CfC ileri geçişlerine gerçek kontrol zaman adımı iletildi. `ncps` kütüphanesinin yığın boyutu kısıtı nedeniyle Δt tensörü $(1, T)$ boyutunda oluşturuldu; bu durumda kütüphanenin iç döngüsü skalar değer ürettiğinden çalışır hale geldi.

5 Sonuçlar

5.1 Eğitim Kaybı Karşılaştırması

Aynı koşullarda 500 dönem eğitimden sonra:

Model	**Başlangıç kaybı**	**Son kayıp (dönem 500)**
GRU (BC)	0.120	1.26×10^{-4}
CfC – düzeltilmiş (BC)	0.122	7.44×10^{-5}

Eğitim kaybı açısından düzeltilmiş CfC, GRU'yu geride bırakmıştır.

5.2 Politika Değerlendirmesi (6 harita, 4 bölüm, max-steps = 900)

Tablo 2 üç modeli aynı koşullarda karşılaştırmaktadır: (1) GRU BC, (2) CfC kırık (düzeltme öncesi), (3) CfC düzeltilmiş + 2 DAgger iterasyonu.

Tablo 2: 6 haritada saf politika değerlendirmesi (4 bölüm, max-steps = 900)

	GRU BC		**CfC kırık**		**CfC düzeltilmiş**	
Harita	Başarı	Ort. Adım	Başarı	Ort. Adım	Başarı	Ort. Adım
`map_01`	0.00	93	0.00	55	**1.00**	445
`map_02`	0.00	312	0.00	19	0.00	900
`map_04`	0.00	126	0.00	161	0.00	900
`map_05`	0.00	648	0.00	128	0.00	900
`map_06`	0.00	103	0.00	103	0.00	900
`map_07`	0.00	242	0.00	180	**1.00**	231
Toplam başarı	0/6		0/6		**2/6**	

Düzeltme öncesi CfC tüm haritalarda çarpışma üretirken (ort. adım 19–180), düzeltme sonrası CfC iki haritada tam başarı, kalan dört haritada ise çarpışmasız 900 adımlık navigasyon elde etmiştir.

5.3 Bulguların Özeti

- CfC başarısızlığının kök nedeni tek bir bug değil; mimari, yapılandırma ve entegrasyon hatalarının birleşimidir.
- Giriş kodlayıcısının eklenmesi tek başına en büyük etkiyi doğurmuştur: çarpışma oranı %100'den %0'a inmiştir.

- Timeout gözlemleri (900 adım, çarpışmasız) modelin engelleri tanıdığını ancak henüz uzun vadeli hedef takibini tam öğrenemediğini göstermektedir.
- DAgger, BC'nin covariate shift sorununu azaltmıştır: 1. DAgger iterasyonu sonrası `map_05`'te %100 başarı, 2. iterasyon sonrası `map_01` ve `map_07`'de %100 başarı elde edilmiştir.

6 Sonuç

Bu çalışmada MuJoCo ortamında LNN/CfC tabanlı robot navigasyonu araştırılmıştır. Vize aşamasında GRU baseline için iki haritada tam başarı elde edilmiş; final aşamasında CfC politikasının neden sıfır başarı ürettiği sistematik biçimde analiz edilmiştir.

Tespit edilen üç sorun — giriş kodlayıcısı eksikliği, asimetrik eğitim bütçesi ve yanlış ODE zaman adımı — düzeltildikten ve iki DAgger iterasyonu uygulandıktan sonra CfC, 6 haritanın 2'sinde tam başarı ve tüm haritalarda çarpışmasız hareket elde etmiştir.

Sonuçlar, CfC'nin eşit mimari koşullar ve doğru ODE entegrasyonu altında GRU ile rekabetçi hale gelebildiğini, ancak uzun vadeli hedef takibini güvenilir biçimde öğrenmesi için ek veri veya pekiştirmeli öğrenme aşamalarına ihtiyaç duyduğunu göstermektedir.